


3. PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG


Kiến trúc module AI — pipeline 2 pha

Điều phối bởi AiFeatureController · tích hợp qua Spring AI ChatClient (trừu tượng nhà cung cấp — có thể thay model)

• PHA A — INGEST / INDEX (offline, @Async)



• PHA B — SINH NỘI DUNG (online · mỗi request)



↓ Đầu ra: JSON có schema → trình soạn thảo SCORM

Toàn bộ fail-soft: RAG lỗi/chưa index → tự fallback nhồi toàn tài liệu, không làm hỏng luồng. Gate chỉ áp cho Quiz; outline/page-content đi thẳng từ LLM.

3. PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG

Vì sao chọn Google Gemini 2.5 Pro?

CSE

01 • Context window cực lớn (~1M token)

Nhồi TOÀN BỘ tài liệu nguồn để bám sát — tài liệu test có cuốn 360 trang.

★ Lý do quyết định: model context nhỏ không grounding nổi.

02 • Đa phương thức (multimodal) gốc

Đọc & hiểu trực tiếp PDF / DOCX / PPT —

đúng định dạng học liệu giảng viên tải lên.

03 • Structured output (JSON) ổn định

Mọi tính năng parse JSON theo schema.

→ Đã đo 100% JSON/schema hợp lệ (60 lượt gọi).

04 • Tiếng Việt tốt + hệ sinh thái thống nhất

Corpus nhiều tài liệu Việt; cùng nhà cung cấp có embedding gemini-embedding-001 cho RAG; quota/chi phí hợp lý.

Tích hợp qua Spring AI ChatClient → trừu tượng hoá nhà cung cấp: có thể THAY MODEL mà không sửa nghiệp vụ (không khoá cứng vendor).

Lưu ý trung thực: chưa chạy bake-off head-to-head GPT/Claude — chọn theo tiêu chí khớp yêu cầu, và chứng minh đạt ngưỡng bằng đánh giá định lượng (phần sau).

4. ĐÁNH GIÁ ĐỊNH LƯỢNG MODULE AI

Phương pháp & khung đo lường

CSE

“Module AI có đáng tin, hiệu quả và sư phạm không? → ĐO LƯỜNG, không KHẢNG ĐỊNH.”

A

Độ tin cậy

B

Độ trễ & Chi phí

C

Trung thực
(chống bịa)

D/E

Sư phạm:
IWF + Bloom

F

RAG vs Nhồi

TẬP DỮ LIỆU & THIẾT LẬP

- 10 tài liệu đa lĩnh vực (CNTT · KHTN · KHXXH · tiếng Anh · tiếng Việt)
- + 3 tài liệu hold-out (chưa từng dùng tune → chống overfitting)
- Model pin gemini-2.5-pro-preview-05-06, temp 0.2 → tái lập được

CHUẨN SƯ PHẠM ĐÁNH GIÁ CHẤT LƯỢNG CÂU HỎI

- Item Writing Flaws — Haladyna (2002): 12 lỗi soạn câu hỏi trắc nghiệm chuẩn → chất lượng kỹ thuật
- Thang Bloom (6 mức: Nhớ→Hiểu→Áp dụng→Phân tích→Đánh giá→Sáng tạo) → cấp độ tư duy & độ khó
- 4 tiêu chí sư phạm: rõ ràng · 1 đáp án đúng · nhiều hợp lý · bám nguồn

4. ĐÁNH GIÁ ĐỊNH LƯỢNG MODULE AI

A + B — Độ tin cậy, độ trễ & chi phí

CSE

100%

JSON parse & schema hợp lệ
(60 lượt gọi)

~20–25s

Độ trễ p50 / lượt
(chi phí ~\$0.02–0.06)

0%

Trường rỗng (sau khi sửa)
— ban đầu 35%

Tính năng	Latency p50	Cost/lượt
Sinh dàn ý	~21s	~\$0.06
Sinh nội dung	~25s	~\$0.024
Sinh quiz	~20s	~\$0.017


💡 Quan sát định lượng

100% đầu ra bị bọc markdown fence dù prompt cấm → cần lớp hậu xử lý stripJsonFence. Phản chứng giả định “ép JSON là hết lỗi cú pháp”.

4. ĐÁNH GIÁ ĐỊNH LƯỢNG MODULE AI

C — Độ trung thực & “trần” hallucination

CSE



Mở rộng Ground-Truth 5→15→25 facts:

- Hallucination chạm TRẦN ~50% — chứng minh là giới hạn phương pháp, không hand-wave.
- Phân rã 50% còn lại (đọc tay 5 ca): 100% là inference-extension, 0 ca mâu thuẫn nguồn.

→ **Tỉ lệ bịa-sai thực tế ước tính 0–10%.**

AI là “trợ lý cần giảng viên duyệt”, không tự động tuyệt đối.

So literature: ChatGPT MCQ 30–40% · RAG-SOTA 5–10% · ta ~50%

4. ĐÁNH GIÁ ĐỊNH LƯỢNG MODULE AI

D/E — Chất lượng câu hỏi & kiểm soát runtime

CSE

68% → 94.4%

Câu KHÔNG lỗi soạn đề (IWF)
trên tài liệu lạ (hold-out)

17/18

Đạt cả 4 tiêu chí sự phạm
(94.4%)

RUNTIME QUALITY GATE (kiểm soát từng câu)

1 · Sinh quiz

2 · Kiểm tra: Schema · Citation trích nguyên văn · Bloom 1–6 · IWF
(TW-1/TW-5/ID-2)

3 · Lỗi? → Tự sửa (retry 1 lần)

4 · Trả kết quả (đếm metric qua Micrometer)

4. ĐÁNH GIÁ ĐỊNH LƯỢNG MODULE AI

F — RAG vs Nhồi tài liệu (đóng góp nổi bật)


CSE

-68.6%

Token đầu vào
(Wilcoxon $p = 0.004$)

-55.7%

Chi phí sinh
($p = 0.002$)



Đánh đổi trung thực: faithfulness -17% ($p=0.027$) do top-k bỏ sót — giảm được bằng tăng top-k / reranking.

4. ĐÁNH GIÁ ĐỊNH LƯỢNG MODULE AI

Tổng kết & tính liên chính phương pháp

CSE

TIN CẬY

100% schema hợp lệ
94% câu không lỗi (hold-out)
Gate tự sửa runtime

TRUNG THỰC

Bịa-sai thực ~0–10%
0 ca mâu thuẫn nguồn
AI = trợ lý có giám sát

HIỆU QUẢ

RAG –69% token
–56% chi phí (significant)
Mở rộng theo độ dài tài liệu

✓ **Liên chính: faithfulness do AI-judge → DISCLOSE rõ không phải human, và KIỂM CHỨNG CHÉO bằng model thứ hai:**

κ (hallucination) = 1.00 · điểm 100% trong ± 1 (QWK 0.66) → judge không phải outlier.

Future work: human rescoring · tăng top-k/reranking · bake-off đa model.

PHỤ LỤC — DỮ LIỆU CHI TIẾT (Q&A)

P1 — Danh sách tài liệu dùng để đo lường

Tập chính (dùng để phát triển & đo) — 10 tài liệu

Mã	Tài liệu	Lĩnh vực	Ngôn ngữ	Quy mô
D01	Programming Languages & Compilers (Intro)	CNTT — Ngôn ngữ LT	EN	36 trang
D02	Structured Query Language — DDL/DML/DCL	CNTT — CSDL	EN	114 trang
D03	Searching Algorithms & Hash Tables	CNTT — CTDL & Giải thuật	EN	124 trang
D04	Transaction Processing Concepts	CNTT — CSDL / Giao dịch	EN	65 trang
D05	Graph Connectivity (Discrete Structures)	Toán rời rạc	EN/VI	360 trang
D06	Bayesian Learning	AI — Học máy	EN	36 trang
D07	Design Thinking (E-Commerce)	TMĐT — Thiết kế	EN	72 trang
D08	Đại cương về Marketing	Kinh tế — Marketing	VI	26 trang
D09	Trường tĩnh điện trong chân không	Vật lý đại cương	VI	25 trang
D10	Supply, Demand & Market Equilibrium	Kinh tế vi mô	EN	57 trang

Tập hold-out (CHƯA từng dùng tune → chống overfitting) — 3 tài liệu

Mã	Tài liệu	Lĩnh vực	Ngôn ngữ	Quy mô
D11	Data Streaming (Chapter 2)	CNTT — Kỹ thuật dữ liệu	EN	~17k ký tự
D12	Những khái niệm chung về Nhà nước	Luật / Chính trị	VI	~14k ký tự
D13	Delta Lake	CNTT — Kỹ thuật dữ liệu	EN	~95k ký tự


13 tài liệu · EN + VI · 25–360 trang · phủ CNTT, Toán, AI, Kinh tế, Marketing, Vật lý, Luật.

PHỤ LỤC — DỮ LIỆU CHI TIẾT (Q&A)

P2 — Kiểm định Wilcoxon signed-rank (paired)

CSE

RAG vs STUFF — % thay đổi theo chỉ số (page-content N=30 • focused-quiz N=10)




Token & chi phí giảm mạnh, có ý nghĩa thống kê ($p \leq 0,006$) ở CẢ HAI chức năng; latency chỉ là xu hướng (ns).

Faithfulness chỉ về cho page-content (đánh đổi -17%, $p=0,027$); chất lượng quiz đo bằng IWF gate (D10), không dùng key-fact judge.

PHỤ LỤC — DỮ LIỆU CHI TIẾT (Q&A)

P3 — RAG vs STUFF theo từng tài liệu (page-content)




Doc	Δ token	Faith S→R
D01	-58%	3,67 → 3,00
D02	-79%	4,67 → 3,33
D03	-88%	2,67 → 2,67
D04	-70%	4,00 → 4,50
D05	-83%	3,67 → 2,00
D06	-59%	4,00 → 4,33
D07	-56%	5,00 → 3,33
D08	+7%	5,00 → 4,33
D09	-34%	3,00 → 2,67
D10	-59%	5,00 → 3,67

D08 (26 trang) +7% token vì top-6 chunk > cả tài liệu · D05 (360 trang) faithfulness giảm mạnh nhất do top-k bỏ sót · Faith = TB 3 lần (loại 1 dòng lỗi D04).

PHỤ LỤC — DỮ LIỆU CHI TIẾT (Q&A)

P4 — Cross-check LLM-judge bằng model thứ hai

CSE



ĐỘ ĐỒNG THUẬN (n=10)

κ hallucination = 1,00

trùng khớp hoàn toàn

QWK (điểm 1–5) = 0,66

khá (substantial)

Đồng thuận ± 1 điểm = 100%

không cặp nào lệch > 1

MAD = 0,60 · TB G/C = 3,40 / 3,80

Claude lenient hơn ~0,4

Gemini-Flash judge vs model thứ 2 (Claude) trên CÙNG key_facts → cross-MODEL, không phải human inter-rater (đã disclose). Judge không phải outlier.